## Learn Convolutional Neural Network in One Day

#### Wei Li

National Chiao-Tung University Computer Games and Intelligence (CGI) Lab

August 22, 2017

/ei Li Learn Convolutional Neural Network in One Day

イロト イポト イヨト イヨト

Artifical Intelligence Machine Learning Image Recognition

- Part of figures in my slide come from the following links:
  - CS231n: Convolutional Neural Networks for Visual Recognition
  - Hung-yi Lee 一日搞懂深度学习
  - Kai-Ming He Deep residual networks tutorial
  - Xiu-Shen Wei Must Know Tips/Tricks in Deep Neural Networks
- See my tutorial for more information.
- I'm a first-year graduate student at National Chiao-Tung University(NCTU).

Please feel free to contact me via e-mail<sup>1</sup> if you have any questions or concerns.

-

Artifical Intelligence Machine Learning Image Recognition

## Artifical Intelligence $\rightarrow$ Just around us



I. robot



WALL-E



The Imitation Game



Ex Machina



Deep Blue



しょうぎ







Object Recognition



Libratus Alan



Robotic Arm



Self-driving



StarCraft2





Learn Convolutional Neural Network in One Day

・ロト ・回ト ・モト ・モト

Artifical Intelligence Machine Learning Image Recognition

# Machine Learning $\approx$ Looking for a Function



Artifical Intelligence Machine Learning Image Recognition

## Image Recognition - NARUTO



▶ Input(Training) data: 『NARUTO -ナルト-』's image

Then we build a model f(.) to predict an image is  $[NARUTO - \mathcal{T} \mathcal{N} \vdash -]$  's character or not.

Artifical Intelligence Machine Learning Image Recognition

# Image Recognition - NARUTO(cont.)

- We can use lots of methods to train our model
- But we only consider Convolution Neural Networks



Learn Convolutional Neural Network in One Day

#### Neural Network Backpropagation Convolutional Layer Pooling Layer ConvNet

## Neural Network

An Artificial Neural Network (ANN) is an information processing paradigm that is inspired by the way biological nervous systems, such as the brain, process information.



イロン イロン イヨン イヨン

э

Neural Network Backpropagation Convolutional Layer Pooling Layer ConvNet

# Neural Network(cont.)

Fully connected neural network = input layer + hidden layer + output layer  $w_0 x_0$ cell body  $\sum w_i x_i + b$  $w_1x_1$  $\sum w_i x_i + b$ output axon output layer activation function  $w_2 x_2$ input layer hidden layer 2 hidden layer 1 5 20  $x_i$ W; h

< ロ > < 同 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ >

Neural Network Backpropagation Convolutional Layer Pooling Layer ConvNet

## Backpropagation



Wei Li

э

Neural Network Backpropagation Convolutional Layer Pooling Layer ConvNet

## Backpropagation(cont.)

- How to update weights? Back Propagation !
- Keyword: Chain Rule



Wei Li

Learn Convolutional Neural Network in One Day

Neural Network Backpropagation Convolutional Layer Pooling Layer ConvNet

## Convolutional Neural Network

- A Convolutional Neural Network (CNN) is comprised of one or more convolutional layers (often with a subsampling step) and then followed by one or more fully connected layers as in a standard multilayer neural network.
  - Convolutional Layer
  - Pooling Layer
  - Fully-Connected Layer(exactly as seen in regular Neural Networks)



Neural Network Backpropagation Convolutional Layer Pooling Layer ConvNet

#### Convolutional Layer



Learn Convolutional Neural Network in One Day

Neural Network Backpropagation Convolutional Layer Pooling Layer ConvNet

# Convolutional Layer(cont.)



Learn Convolutional Neural Network in One Day

<ロ> <同> <同> < 同> < 同>

Neural Network Backpropagation Convolutional Layer Pooling Layer ConvNet

## Convolutional Layer(cont.)







If we had 6 5x5 filters, we'll get 6 separate feature maps The depth of the output is equal to the number of filters

Learn Convolutional Neural Network in One Day

< ロ > < 同 > < 回 > < 回 >

Neural Network Backpropagation Convolutional Layer Pooling Layer ConvNet

## Convolutional Layer(cont.)



< ロ > < 同 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ >

Neural Network Backpropagation Convolutional Layer **Pooling Layer** ConvNet

# Pooling Layer



Learn Convolutional Neural Network in One Day

Neural Network Backpropagation Convolutional Layer Pooling Layer ConvNet

э

## ConvNet



Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## Convolutional Neural Network Architectures

- LeNet-5
- AlexNet
- Network in Network
- VGG Network
- GoogLeNet
- Residual Network
- Wide Residual Network
- ResNeXt Network
- DenseNet
- Dual Path Network

(a)

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## LeNet-5 - Overview

- The first successful applications of Convolutional Networks were developed by Yann LeCun in 1990's.
- Paper: Gradient-Based Learning Applied to Document Recognition
- Project page: lecun-lenet



Learn Convolutional Neural Network in One Day

イロト 不得 トイヨト イヨト 二日

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## AlexNet - Overview

- The first work that popularized Convolutional Networks in Computer Vision
- ImageNet 2012 winner
- Paper: ImageNet Classification with Deep Convolutional Neural Networks



#### Basic Networks

VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## AlexNet - Detail

Full (simplified) AlexNet architecture: [227x227x3] INPUT [55x55x96] CONV1: 96 11x11 filters at stride 4, pad 0 [27x27x96] MAX POOL1: 3x3 filters at stride 2 [27x27x96] NORM1: Normalization layer [27x27x256] CONV2: 256 5x5 filters at stride 1, pad 2 [13x13x256] MAX POOL2: 3x3 filters at stride 2 [13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1 [13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1 [13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1 [13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1 [13x13x256] MAX POOL3: 3x3 filters at stride 2 [4096] FC6: 4096 neurons [4096] FC6: 4096 neurons [4096] FC6: 1000 neurons (class scores)

#### **Details/Retrospectives:**

- first use of ReLU
- used Norm layers (not common anymore)
- heavy data augmentation
- dropout 0.5
- batch size 128
- SGD Momentum 0.9
- Learning rate 1e-2, reduced by 10
- manually when val accuracy plateaus
- L2 weight decay 5e-4
- 7 CNN ensemble: 18.2% -> 15.4%



Historical note: Trained on GTX 580 GPU with only 3 GB of memory. Network spread across 2 GPUs, half the neurons (feature maps) on each GPU.

< ロ > < 同 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ >

 $[55 \times 55 \times 48] \times 2$ 

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

#### Network in Network - Mlpconv

#### Paper: Network In Network

![](_page_21_Picture_4.jpeg)

Mlpconv layer

![](_page_21_Figure_6.jpeg)

(a) Linear convolution layer

(b) Mlpconv layer

・ロト ・四ト ・ヨト ・ヨト

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## Network in Network - Global average pooling

![](_page_22_Figure_3.jpeg)

Wei Li

э

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## VGG Network - Overview

- Paper: Very Deep Convolutional Networks for Large-Scale Image Recognition
- Project page: Visual Geometry Group

![](_page_23_Figure_5.jpeg)

8 layers (AlexNet) → 19 layers (VGGNet)

11x11(5x5,3x3) conv → 3x3 conv

11.7% top 5 error in ILSVRC'13(ZFNet) → 7.3% top 5 error in ILSVRC'14

Why use smaller filters? (3x3 conv)

- 1. Stack of three 3x3 conv (stride 1) layers has same effective receptive field as one 7x7 conv layer
- 2. But the network is deeper and more non-linearity
- 3. And fewer parameter:

< ロ > < 同 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ >

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

### VGG Network - Calculate params

![](_page_24_Figure_3.jpeg)

![](_page_24_Figure_4.jpeg)

< ロ > < 同 > < 回 > < 回 > .

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

#### VGG Network - Detail

![](_page_25_Figure_3.jpeg)

Learn Convolutional Neural Network in One Day

< ロ > < 同 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < 回 > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ > < □ >

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## GoogLeNet - Overview

#### Papers

- [V1]: Going Deeper with Convolutions
- [V2]: Accelerating Deep Network Training by Reducing Internal Covariate Shift
- [V3]: Rethinking the Inception Architecture for Computer Vision
- [V4]: Inception-v4, Inception-ResNet and the Impact of Residual Connections on Learning

![](_page_26_Figure_8.jpeg)

(a)

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## GoogLeNet - Inceptions

![](_page_27_Figure_3.jpeg)

his constant of the second sec

Wei Li

Learn Convolutional Neural Network in One Day

э

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## GoogLeNet - Detail

![](_page_28_Figure_3.jpeg)

Inception module with dimension reduction

pooling layer

Learn Convolutional Neural Network in One Day

イロン 不同 とくほう イロン

-

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## Residual Network - Overview

#### Papers

- Deep Residual Learning for Image Recognition
- Identity Mappings in Deep Residual Networks
- · MSRA Kaiming He
- · 152-layer model for ImageNet
- ILSVRC'15 classification winner (3.57% top 5 error)
- Swept all classification and detection competitions in ILSVRC'15 and COCO'15

Full ResNet Architecture:

- Stack residual blocks
- · Every residual block has two 3x3 conv layers
- Periodically, double # of filters and downsample spatially using stride 2 (/2 in each dimension)
- · Additional conv layer at the beginning
- · No FC layers at the end (only FC 1000 to outputclasses)

![](_page_29_Figure_16.jpeg)

Basic Networks VGG and GoogLeNet Residual Network and Variants Dual Path Networks

## Residual Network - Residual Block

![](_page_30_Figure_3.jpeg)

![](_page_30_Figure_4.jpeg)

"We hypothesize that it is easier to optimize the residual mapping than to optimize the original, unreferenced mapping"----authors

<ロ> <同> <同> < 回> < 回>

э

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## Residual Network - Bottleneck

![](_page_31_Figure_3.jpeg)

Residual block: 2 layers (3-3)

Params:  $(3 \times 3 \times 64) * 64$   $+(3 \times 3 \times 64) * 64$ = 73K

Bottleneck: 3 layers (1-3-1)

Params:  $(1 \times 1 \times 64) * 64$   $+(3 \times 3 \times 64) * 64$   $+(1 \times 1 \times 64) * 256$   $+(1 \times 1 \times 64) * 256$ = 73K

_	34-layer	50-layer	
_		7×7, 64, stride 2	
_		3×3 max pool, stric	le :
!	$\left[\begin{array}{c} 3\times3,64\\ 3\times3,64 \end{array}\right]\times3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	
2	$\left[\begin{array}{c} 3\times3,128\\3\times3,128\end{array}\right]\times4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	
2	$\left[\begin{array}{c} 3\times3,256\\ 3\times3,256\end{array}\right]\times6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	
2	$\left[\begin{array}{c} 3\times3,512\\ 3\times3,512\end{array}\right]\times3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	
_	ave	erage pool, 1000-1 fc,	so
_	$3.6 \times 10^9$	$3.8 \times 10^{9}$	

both designs have similar time complexity

イロト 不得 とうせい かほとう ほ

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

#### Residual Network - Identity mapping

![](_page_32_Figure_3.jpeg)

Learn Convolutional Neural Network in One Day

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## Wide Residual Network - Overview

Paper: Wide Residual Networks

![](_page_33_Figure_3.jpeg)

	depth-k	# params	CIFAR-10	CIFAR-100
	110	1.7M	6.37	-
pre-act-ResNet[13]	164	1.7M	5.46	24.33
	1001	10.2M	4.92(4.64)	22.71
	40-4	8.9M	4.53	21.18
WRN (ours)	16-8	11.0M	4.27	20.43
	28-10	36.5M	4.00	19.25

depth	k	dropout	CIFAR-10	CIFAR-100	SVHN
16	4		5.02	24.03	1.85
16	4	√	5.24	23.91	1.64
28	10		4.00	19.25	-
28	10	1	3.89	18.85	-
52	1		6.43	29.89	2.08
52	1	√	6.28	29.78	1.70

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## ResNeXt Network - Overview

#### Paper: Aggregated Residual Transformations for Deep Neural Networks

![](_page_34_Figure_4.jpeg)

	224×224		320×320/299×2		
	top-1 err	top-5 err	top-1 err	top-5 err	
ResNet-101 [14]	22.0	6.0	-	-	
ResNet-200 [15]	21.7	5.8	20.1	4.8	
Inception-v3 [39]	-	-	21.2	5.6	
Inception-v4 [37]	-	-	20.0	5.0	
Inception-ResNet-v2 [37]	-	-	19.9	4.9	
ResNeXt-101 ( $64 \times 4d$ )	20.4	5.3	19.1	4.4	

	# params	CIFAR-10	CIFAR-100
Wide ResNet [43]	36.5M	4.17	20.50
ResNeXt-29, 8×64d	34.4M	3.65	17.77
ResNeXt-29, 16×64d	68.1M	3.58	17.31

<ロ> <部> < 部> < き> < き> < き</p>

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## DenseNet - Overview

![](_page_35_Figure_3.jpeg)

![](_page_35_Figure_4.jpeg)

・ロン ・四 と ・ ヨ と ・ ヨ と ・

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## DenseNet - Detail

#### DenseNet architectures for ImageNet

Layers	Output Size	DenseNet- $121(k = 32)$	DenseNet-169 $(k = 32)$	DenseNet-201 $(k = 32)$	DenseNet-161 $(k = 48)$		
Convolution	$112 \times 112$	$7 \times 7$ conv, stride 2					
Pooling	$56 \times 56$		3 × 3 max p	oool, stride 2			
Dense Block (1)	56 × 56	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$		
Transition Layer	$56 \times 56$		$1 \times 1$	conv			
(1)	$28 \times 28$		$2 \times 2$ average	pool, stride 2			
Dense Block (2)	$28 \times 28$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$		
Transition Layer	$28 \times 28$		$1 \times 1$	conv			
(2)	$14 \times 14$		$2 \times 2$ average	pool, stride 2			
Dense Block (3)	$14 \times 14$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 24$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 48$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 36$		
Transition Layer	$14 \times 14$	1 × 1 conv					
(3)	$7 \times 7$	$2 \times 2$ average pool, stride 2					
Dense Block (4)	7 × 7	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 16$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 24$		
Classification	$1 \times 1$	7 × 7 global average pool					
Layer			1000D fully-con	nnected, softmax			

Learn Convolutional Neural Network in One Day

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

#### DenseNet - Results

#### Error rates on CIFAR and SVHN datasets

Method	Depth	Params	C10	C10+	C100	C100+	SVHN
Network in Network [22]	-	-	10.41	8.81	35.68	-	2.35
All-CNN [31]	-	-	9.08	7.25	-	33.71	-
Deeply Supervised Net [20]	-	-	9.69	7.97	-	34.57	1.92
Highway Network [33]	-	-		7.72	-	32.39	-
FractalNet [17]	21	38.6M	10.18	5.22	35.34	23.30	2.01
with Dropout/Drop-path	21	38.6M	7.33	4.60	28.20	23.73	1.87
ResNet [11]	110	1.7M	-	6.61	-	-	-
ResNet (reported by [13])	110	1.7M	13.63	6.41	44.74	27.22	2.01
ResNet with Stochastic Depth [13]	110	1.7M	11.66	5.23	37.80	24.58	1.75
	1202	10.2M	-	4.91	-	-	-
Wide ResNet [41]	16	11.0M	-	4.81	-	22.07	-
	28	36.5M		4.17	-	20.50	-
with Dropout	16	2.7M	-	-	-	-	1.64
ResNet (pre-activation) [12]	164	1.7M	11.26*	5.46	35.58*	24.33	-
	1001	10.2M	10.56*	4.62	33.47*	22.71	-
DenseNet $(k = 12)$	40	1.0M	7.00	5.24	27.55	24.42	1.79
DenseNet $(k = 12)$	100	7.0M	5.77	4.10	23.79	20.20	1.67
DenseNet $(k = 24)$	100	27.2M	5.83	3.74	23.42	19.25	1.59
DenseNet-BC $(k = 12)$	100	0.8M	5.92	4.51	24.15	22.27	1.76
DenseNet-BC $(k = 24)$	250	15.3M	5.19	3.62	19.64	17.60	1.74
DenseNet-BC $(k = 40)$	190	25.6M	-	3.46	-	17.18	-

Learn Convolutional Neural Network in One Day

<ロ> <部> < 部> < き> < き> < き</p>

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## Dual Path Networks - Overview

- Paper: Dual Path Networks
- Github: cypw/DPNs
- ResNet + DenseNet ⇒ Dual Path Networks

![](_page_38_Figure_6.jpeg)

<ロ> <同> <同> < 同> < 同>

э

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## Dual Path Networks - Detail

stage output	DenseNet-161 (k=48)	ResNeXt-101 (32×4d)	ResNeXt-101 (64×4d)	DPN-92 (32×3d)	DPN-98 (40×4d)
conv1   112x112	7 × 7, 96, stride 2	$7 \times 7, 64$ , stride 2	$7 \times 7, 64$ , stride 2	7 × 7, 64, stride 2	$7 \times 7, 96$ , stride 2
	$3 \times 3$ max pool, stride 2	$3 \times 3$ max pool, stride 2	$3 \times 3$ max pool, stride 2	$3 \times 3$ max pool, stride 2	$3 \times 3$ max pool, stride 2
conv2 56x56	$\left[\begin{array}{c} 1 \times 1, 192 \\ 3 \times 3, 48 \end{array}\right] \times \ 6$	$\left[\begin{array}{c} 1 \times 1, 128 \\ 3 \times 3, 128, G=32 \\ 1 \times 1, 256 \end{array}\right] \times 3$	$\left[\begin{array}{c} 1 \times 1, 256 \\ 3 \times 3, 256, G{=}64 \\ 1 \times 1, 256 \end{array}\right] \times 3$	$\left[\begin{array}{c} 1 \times 1, 96 \\ 3 \times 3, 96, G=32 \\ 1 \times 1, 256 \ (+16) \end{array}\right] \times 3$	$\left[ \begin{array}{c} 1 \times 1, 160 \\ 3 \times 3, 160, G{=}40 \\ 1 \times 1, 256  ({+}16) \end{array} \right] \times  3$
conv3 28×28	$\left[\begin{array}{c}1\times1,192\\3\times3,48\end{array}\right]\times12$	$\left[\begin{array}{c} 1 \times 1, 256 \\ 3 \times 3, 256, G=32 \\ 1 \times 1, 512 \end{array}\right] \times 4$	$\left[\begin{array}{c}1\times1,512\\3\times3,512,G=64\\1\times1,512\end{array}\right]\times4$	$\left[\begin{array}{c} 1 \times 1, 192 \\ 3 \times 3, 192, G=32 \\ 1 \times 1, 512 (+32) \end{array}\right] \times 4$	$\left[\begin{array}{c} 1 \times 1, 320 \\ 3 \times 3, 320, G = 40 \\ 1 \times 1, 512 \ (+32) \end{array}\right] \times 6$
conv4 14×14	$\left[\begin{array}{c}1\times1,192\\3\times3,48\end{array}\right]\times36$	$\left[\begin{array}{c}1\times1,512\\3\times3,512,G=32\\1\times1,1024\end{array}\right]\times23$	$\left[\begin{array}{c}1\times1,1024\\3\times3,1024,G=\!64\\1\times1,1024\end{array}\right]\times23$	$\left[\begin{array}{c} 1 \times 1, 384 \\ 3 \times 3, 384, G=32 \\ 1 \times 1, 1024 \ (+24) \end{array}\right] \times 20$	$\left[\begin{array}{c} 1 \times 1, 640 \\ 3 \times 3, 640, G{=}40 \\ 1 \times 1, 1024 \ ({+}32) \end{array}\right] \times 20$
conv5 7×7	$\left[\begin{array}{c}1\times1,192\\3\times3,48\end{array}\right]\times24$	$\left[\begin{array}{c} 1 \times 1, 1024 \\ 3 \times 3, 1024, G=32 \\ 1 \times 1, 2048 \end{array}\right] \times 3$	$\left[ \begin{array}{c} 1 \times 1, 2048 \\ 3 \times 3, 2048, G = 64 \\ 1 \times 1, 2048 \end{array} \right] \times 3$	$\left[\begin{array}{c} 1 \times 1,768 \\ 3 \times 3,768, G=32 \\ 1 \times 1,2048 \ (+128) \end{array}\right] \times 3$	$\left[\begin{array}{c} 1 \times 1, 1280 \\ 3 \times 3, 1280, G=\!40 \\ 1 \times 1, 2048 (+128) \end{array}\right] \times 3$
1×1	global average pool 1000-d fc, softmax	global average pool 1000-d fc, softmax	global average pool 1000-d fc, softmax	global average pool 1000-d fc, softmax	global average pool 1000-d fc, softmax
# params	$28.9 \times 10^{6}$	$44.3  imes 10^6$	$83.7\times10^{6}$	$37.8 \times 10^{6}$	$61.7 \times 10^{6}$
FLOPs	$7.7  imes 10^9$	$8.0  imes 10^9$	$15.5  imes 10^9$	$6.5  imes 10^9$	$11.7 \times 10^9$

ヘロト ヘヨト ヘヨト ヘヨト

Basic Networks VGG and GoogLeNet Residual Network and Variants DenseNet Dual Path Networks

## Dual Path Networks - Results

Mathad	Model	CELOD.	x224		x320/	′ x299
Method	Size	ize		top-5	top-1	top-5
DenseNet-161(k=48) [8]	111 MB	7.7	22.2	-	-	-
ResNet-101* [5]	170 MB	7.8	22.0	6.0	-	-
ResNeXt-101 (32 × 4d) [21]	170 MB	8.0	21.2	5.6	-	-
DPN-92 $(32 \times 3d)$	145 MB	6.5	20.7	5.4	19.3	4.7
ResNet-200 [6]	247 MB	15.0	21.7	5.8	20.1	4.8
Inception-resnet-v2 [20]	227 MB	-	-	_	19.9	4.9
ResNeXt-101 (64 × 4d) [21]	320 MB	15.5	20.4	5.3	19.1	4.4
DPN-98 $(40 \times 4d)$	236 MB	11.7	20.2	5.2	18.9	4.4
Very deep Inception-resnet-v2 [23]	531 MB	-	-	-	19.10	4.48
Very Deep PolyNet [23]	365 MB	-	-	-	18.71	4.25
DPN-131 $(40 \times 4d)$	304 MB	16.0	19.93	5.12	18.62	4.23
DPN-131 (40 $\times$ 4d) †	304 MB	16.0	19.93	5.12	18.55	4.16

Method	Model	top-1	top-5
method	Size	acc.	acc.
AlexNet [24]	223 MB	53.17	82.89
GoogleLeNet [24]	44 MB	53.63	83.88
VGG-16 [24]	518 MB	55.24	84.91
ResNet-152 [24]	226 MB	54.74	85.08
ResNeXt-101 [3]	165 MB	56.21	86.25
CRU-Net-116 [3]	163 MB	56.60	86.55
DPN-92 $(32 \times 3d)$	138 MB	56.84	86.69

![](_page_40_Figure_5.jpeg)

<ロ> (四) (四) (三) (三)

э

Pre-Processing Data Augmentation Initializations Regularizations Fine-tune

# **Training Tricks**

- Pre-Processing
- Data Augmentation
- Initializations
- Regularizations
- Fine-tune

#### i Li Learn Convolutional Neural Network in One Day

・ロト ・四ト ・ヨト ・ヨト

э

Pre-Processing Data Augmentation Initializations Regularizations Fine-tune

## **Pre-Processing**

![](_page_42_Figure_3.jpeg)

Wei Li

Learn Convolutional Neural Network in One Day

Pre-Processing Data Augmentation Initializations Regularizations Fine-tune

## Data Augmentation

![](_page_43_Picture_3.jpeg)

Original

![](_page_43_Picture_5.jpeg)

Rotation

![](_page_43_Picture_7.jpeg)

Flip horizontally

![](_page_43_Picture_9.jpeg)

Translation

![](_page_43_Picture_11.jpeg)

Random crops

![](_page_43_Picture_13.jpeg)

Random resize

![](_page_43_Picture_15.jpeg)

Color jittering

<ロ> (日) (日) (日) (日) (日)

Pre-Processing Data Augmentation Initializations Regularizations Fine-tune

### Initializations

- Random Normal
- Random Uniform
- Lecun Uniform

#### Glorot Normal

It draws samples from a uniform distribution within [-limit, limit] where limit is sqrt(6 / (fan\_in + fan\_out)) where fan\_in is the number of input units in the weight tensor and fan\_out is the number of output units in the weight tensor.

#### He Normal - Current Recommendation

It draws samples from a truncated normal distribution centered on 0 with stddev = sqrt(2 / fan\_in) where fan\_in is the number of input units in the weight tensor.

Pre-Processing Data Augmentation Initializations **Regularizations** Fine-tune

# Regularizations

L1 regularization

• 
$$C = C_0 + \frac{\lambda}{n} \sum_{w} |w|$$

L2 regularization(Weight Decay)

• 
$$C = C_0 + \frac{\lambda}{2n} \sum_w w^2$$

Dropout

![](_page_45_Figure_8.jpeg)

Learn Convolutional Neural Network in One Day

・ロト ・回ト ・ヨト ・ヨト

э

Pre-Processing Data Augmentation Regularizations Fine-tune

#### Fine-tune

![](_page_46_Figure_3.jpeg)

Learn Convolutional Neural Network in One Day

## Summary of CNN

![](_page_47_Figure_2.jpeg)

Learn Convolutional Neural Network in One Day